

# Normalverteilung

Peter Büchel

HSLU I

ASTAT: Block 07

# Kontinuierliche Messdaten

- In vielen Anwendungen: Keine diskreten Daten, sondern *Messdaten*
- Messdaten können jeden Wert in einem bestimmten Bereich annehmen
- Bsp: Gemessene Körpergrößen (in cm) können *jeden* Wert im Intervall  $[0, 500]$  annehmen

- Also auch:

145.325 986 54 ...

- Voraussetzung: Beliebige genaue Messung möglich

# Definitionen

- Wertebereich  $W_X$  einer Zufallsvariable  $\rightarrow$  Menge aller Werte, die  $X$  annehmen kann
- Zufallsvariable  $X$  *stetig*: Wertebereich  $W_X$  kontinuierlich
- Kontinuierliche Menge: Hier Ausschnitt aus der Zahlengeraden
- Kontinuierlich: „Zusammenhängend“ und nicht „löchrig“, wie Menge  $\{1, 2, 3\}$
- Wichtige kontinuierliche Wertebereich:

$$W_X = \mathbb{R}, \mathbb{R}^+ \quad \text{oder} \quad [0, 1]$$

- Letzter Fall: Zahlen 0 und 1 *und* alle Zahlen dazwischen

# Intervalle

- Intervall, wo die Grenzen innerhalb oder ausserhalb des Intervalls sein sollen → eckige und runde Klammern
  - ▶ Runde Klammer: Wert ausserhalb des Intervalls
  - ▶ Eckige Klammer: Wert innerhalb des Intervalls
- Intervall  $(a, b]$ : Alle Punkte  $x$  mit  $x > a$  und  $x \leq b$

# Beispiel

- Intervall

$$(1.2, 2.5]$$

- ▶ Enthält die Zahl 1.2 nicht, die Zahl 2.5 schon

- Unterschied zum Intervall

$$[1.2, 2.5]$$

- Es enthält nur den einen Punkt 1.2 der Zahlengeraden mehr
- Statistik: Spielt keine Rolle, ob 1. oder 2. Intervall verwendet wird

# Punktwahrscheinlichkeit 0

- W'keitsverteilung einer *diskreten* Zufallsvariablen: „Punkt“-W'keiten  $P(X = x)$  für alle möglichen  $x$  im Wertebereich
- Vorher:  $X$  Körpergrösse auf cm gerundet  $\rightarrow P(X = 174)$  nicht 0
- Stetige Zufallsvariable  $X$ : Für alle  $x \in W_X$  gilt:

$$P(X = x) = 0$$

- Folgerung: W'keitsverteilung von  $X$  kann *nicht* mittels „Punkt“-W'keiten beschrieben werden

## Beispiel: Körpergrösse

- Messen Körpergrösse von Personen
- W'keit *genau* eine Körpergrösse von 182.254 680 895 434 ... cm zu messen ist gleich 0:

$$P(X = 182.254\,680\,895\,434 \dots) = 0$$

- Verwendung der W'keit einen exakten Messwert zu messen, bringt nichts für W'keitsverteilung der Körpergrösse
- Summe aller W'keiten müsste 1 ergeben → Ist nicht der Fall
- Aber möglich: W'keit, dass ein Messwert in einem bestimmten *Bereich* liegt

- Beispiel: zwischen 174 und 175 cm:

$$P(174 < X \leq 175)$$

- Diese W'keit ist dann nicht mehr 0

- Da

$$P(X = 174) = P(X = 175) = 0$$

gilt

$$P(174 < X \leq 175) = P(174 \leq X \leq 175) = P(174 < X < 175)$$

- Neuer Begriff: W'keitsdichte



# Eigenschaften Wahrscheinlichkeitsdichte

Für eine W'keitsdichte  $f(x)$  gelten folgende Eigenschaften:

- Es gilt:

$$f(x) \geq 0$$

Das heisst, die Kurve liegt überhalb der  $x$ -Achse


- W'keit

$$P(a < X \leq b)$$

entspricht der Fläche zwischen  $a$  und  $b$  unter  $f(x)$

- Die gesamte Fläche unter der Kurve ist 1:
  - ▶ Dies ist die W'keit, dass *irgendein* Wert gemessen wird

- Skizze:




- Wichtig: Zusammenhang zwischen W'keit und Flächen:

### Merkregel

Für stetige W'keitsverteilungen entsprechen W'keiten Flächen unter der Dichtefunktion.

# Beispiel: Wahrscheinlichkeitsdichtefunktion


- Skizze:



- W'keitsdichtefunktionen müssen keine „schöne“ Form haben
- Normalerweise aber „schöne“ Form vorhanden

# Quantile

- Stetige Verteilungen:  $\alpha$ -Quantil  $q_\alpha$  derjenige Wert, wo die Fläche (W'keit) unter der Dichtefunktion von  $-\infty$  bis  $q_\alpha$  gerade  $\alpha$  entspricht
- 50 %-Quantil: *Median*
- Skizze:



## Beispiel: Körpergrösse

- Messen wieder die Körpergrösse
- Beispiel: Für  $\alpha = 0.75$  ist das zugehörige Quantil

$$q_{\alpha} = 182.5$$

- D.h.: 75 % der gemessenen Personen kleiner oder gleich 182.5 cm

# Normalverteilung (Gaussverteilung): $X \sim \mathcal{N}(\mu, \sigma^2)$

- Definition muss man einmal gesehen haben

- *Wertebereich*

$$W = (-\infty, \infty)$$

- *Dichte*

$$f(x) = \frac{1}{\sqrt{2\pi}\sigma} \exp \left\{ -\frac{1}{2} \left( \frac{x - \mu}{\sigma} \right)^2 \right\}$$


- *Erwartungswert*

$$E[X] = \mu$$

- *Varianz*

$$\text{Var}(X) = \sigma^2$$

# Normalverteilung: Illustration Dichten



# Eigenschaften der Normalverteilung

- Dichtefunktionen „glockenförmig“
- Durch Parameter  $\mu$  Verschiebung der Kurve:
  - ▶ Nach rechts, falls  $\mu$  positiv
  - ▶ Nach links, falls  $\mu$  negativ
- Durch Parameter  $\sigma$  wird die Kurve
  - ▶ schmal und hoch um  $\mu$ , falls  $\sigma$  klein (nahe bei 0)
  - ▶ weit und tief um  $\mu$ , falls  $\sigma$  gross




## Beispiel mit R: Verteilung von IQ

- Anwendung: Häufigste Verteilung für Messwerte
- Beispiel: IQ Tests folgen einer Normalverteilung mit Mittelwert 100 und Standardabweichung 15
- $X$  misst den IQ einer zufällig ausgewählten Person
- $X$  normalverteilt mit  $\mu = 100$  und  $\sigma = 15$
- Notation:

$$X \sim \mathcal{N}(100, 15^2)$$

## Beispiel

- Wie gross die W'keit ist, dass jemand einen IQ von mehr als 130 hat, also als hochbegabt gilt?
- $P(X > 130)$ , wobei  $X \sim \mathcal{N}(100, 15^2)$
- Skizze:



- Berechnung von  $P(X > 130)$  mit R-Befehl `pnorm(...)`
- Dieser berechnet die W'keit:

$$P(X \leq 130)$$

- Beachte: Richtung des Ungleichheitszeichens!
- Berechnung:

```
pnorm(q = 130, mean = 100, sd = 15)
## [1] 0.9772499
```

- Befehl `pnorm(...)` berechnet Fläche (W'keit) von  $-\infty$  bis  $q = 130$  unter der Normalverteilungskurve mit  $\mu = 100$  und  $\sigma = 15$
- Dies ist aber *nicht* gesuchte W'keit  $P(X > 130)$

- Aber: Gesamtfläche unter der Kurve 1 → Gesuchte W'keit wie folgt schreiben:


$$P(X > 130) = 1 - P(X \leq 130)$$

- Berechnung mit R:

```
1 - pnorm(q = 130, mean = 100, sd = 15)
## [1] 0.02275013
```

- Also rund 2 % der Bevölkerung ist hochbegabt

- Welches Intervall enthält 95 % der IQ's um den Mittelwert  $\mu = 100$ ?
- W'keit als Fläche:



- Grüne Fläche: 95 % der Gesamtfläche
- Kleine weissen Flächen links und rechts: Jeweils 0.025.

- W'keiten gegeben → Suchen die zugehörigen Werte
- Bestimmung der Quartile  $q_{0.025}$  und  $q_{0.975}$
- R:

```
qnorm(p = 0.025, mean = 100, sd = 15)
## [1] 70.60054
qnorm(p = 0.975, mean = 100, sd = 15)
## [1] 129.3995
```

- Oder kürzer:

```
qnorm(p = c(0.025, 0.975), mean = 100, sd = 15)
## [1] 70.60054 129.39946
```


- 95 % der Menschen haben einen IQ zwischen ungefähr 70 und 130
- Entspricht Abstand von etwa 2 Standardabweichungen vom Mittelwert  $\mu = 100$ .

- Wieviel Prozent der Bevölkerung liegen innerhalb einer Standardabweichung vom Mittelwert liegen?

- Gesucht W'keit:

$$P(85 \leq X \leq 115)$$

- W'keit als Fläche:



- Mit R:

```
pnorm(q = 115, mean = 100, sd = 15) - pnorm(85, 100, 15)  
## [1] 0.6826895
```

- D.h.: Etwa  $\frac{2}{3}$  der Bevölkerung hat einen IQ zwischen 85 und 115



# Normalverteilung: Eigenschaften

- Letzte Resultat aus Beispiel gilt für alle Normalverteilung  $\mathcal{N}(\mu, \sigma^2)$
- Die W'keit, dass eine Beobachtung eine höchstens Standardabweichung vom Erwartungswert abweicht, ist etwa  $\frac{2}{3}$ :

$$P(\mu - \sigma \leq X \leq \mu + \sigma) \approx \frac{2}{3}$$

- Normalverteilung: Konkrete Aussage für die Streuung als „mittlere“ Abweichung vom Erwartungswert
- W'keit, dass eine Beobachtung höchstens zwei Standardeinheiten vom Erwartungswert abweicht:

$$P(\mu - 2\sigma \leq X \leq \mu + 2\sigma) \approx 0.95$$

# Normalverteilung: Eigenschaften

$f(x)$

