

# Vertrauensintervall Zweistichprobentest Wilcoxon-Test

Peter Büchel

HSLU I

ASTAT: Block 10

## Vertrauensintervall


- Bei Punktschätzung für Mittelwert  $\mu$  einer Messreihe  $\rightarrow$  *Einziger* Zahlwert
- Wissen aber nicht, wie nahe dieser geschätzte Mittelwert beim wahren, aber meist unbekannten, Mittelwert der Verteilung der Messreihe liegt
- Vertrauensintervall: Intervall, das angibt, wo, grob gesagt, der wahre Mittelwert mit einer bestimmten vorgegebenen W'keit liegt
- Wollen mit Beispiel Vertrauensintervall verschaulichen

## Beispiel

- Bestimmung Verwerfungsbereiches beim z-Test: Gehen vom einem wahren (aber unbekannten) Wert  $\mu$  aus und einer bekannten Standardabweichung aus
- Bestimmen Quartile  $q_{0.025}$  und  $q_{0.975}$  (zweiseitiger Test,  $\alpha = 0.05$ )
- Normalverteilungskurve  $X \sim \mathcal{N}(5, 2^2)$
- $q_{0.025}$ - und  $q_{0.975}$ -Quantile

```
qnorm(p = c(0.025, 0.975), mean = 5, sd = 2)
## [1] 1.080072 8.919928
```


- Abbildung: Normalverteilungskurve mit dem Verwerfungsbereich rot:



- Liegt nun  $\bar{x}_n$  im Verwerfungsbereich (roter Bereich), dann wird die Nullhypothese  $H_0$  verworfen

- Wahres  $\mu$  praktisch immer unbekannt: Wert einfach angenommen
- Frage umkehren: Kennen  $\bar{x}_n$  und fragen, für welche  $\mu$  wird  $H_0$  nicht verworfen
- Kann man rechnerisch herleiten, machen es aber nur graphisch
- Annahme  $\mu_0 = 5$
- Gegeben  $\bar{x}_n = 6$  und zeichnen Verwerfungsbereich für diesen Wert ein


• Abbildung:



• Linien:


- ▶ Dicke roten Linien: Verwerfungsbereich für  $\bar{x}_n = 6$
- ▶ Dünne roten Linien: Verwerfungsbereich für  $\mu_0 = 5$
- ▶ Vertikaler schwarze Strich:  $\bar{x}_n = 6$
- ▶ Vertikaler blauer Strich:  $\mu_0 = 5$

- Stellen fest:  $\bar{x}_n$  und  $\mu_0$  nicht innerhalb in einem der beiden Verwerfungsbereiche
- Idee:  $\bar{x}_n$  vergrößern und  $\mu_0 = 5$  konstant lassen
- Abbildung:  $\bar{x}_n = 8$ :



- Auch hier:  $\bar{x}_n$  und  $\mu_0$  nicht innerhalb der beiden Verwerfungsbereiche


• Abbildung:  $\bar{x}_n = 9.5$



- Andere Situation:  $\bar{x}_n$  (schwarze Linie) im Verwerfungsbereich von  $\mu_0 = 5$  (dünne blaue Linien)
- Nullhypothese  $H_0$  nun verworfen
- Aber:  $\mu_0 = 5$  im Verwerfungsbereich für  $\bar{x}_n = 9.5$ .

- Andere Darstellung: Bereich, der *nicht* zum Verwerfungsbereich gehört

- Dieses Intervall heisst *Vertrauensintervall*



- Wert 5 liegt nicht im Vertrauensintervall:

```
qnorm(p = c(0.025, 0.975), mean = 9.5, sd = 2)
## [1] 5.580072 13.419928
```

## Interpretation: Vertrauensintervall

- Annahme: Kennen wahre Verteilung  $\mathcal{N}(5, 2^2)$
- Es gilt also  $\mu = \mu_0 = 5$
- Wählen Zufallszahl aus, die Normalverteilung  $\mathcal{N}(5, 2^2)$  folgt

```
set.seed(1)
m <- rnorm(n = 1, mean = 5, sd = 2)
m
## [1] 3.747092
```

- Bestimmen Vertrauensintervall von 3.7470924:

```
qnorm(p = c(0.025, 0.975), mean = m, sd = 2)
## [1] -0.1728356 7.6670203
```

- Feststellung  $\mu_0 = 5$  liegt im Vertrauensintervall

- Wählen andere Zufallszahl aus, die Normalverteilung  $\mathcal{N}(5, 2^2)$  folgt

```
set.seed(7)
m <- rnorm(n = 1, mean = 5, sd = 2)
m
## [1] 9.574494
```

- Bestimmen Vertrauensintervall von 9.5744943:

```
qnorm(p = c(0.025, 0.975), mean = m, sd = 2)
## [1] 5.654566 13.494422
```

- Feststellung  $\mu_0 = 5$  liegt nicht im Vertrauensintervall
- Frage: In wievielen Fällen liegt  $\mu_0 = 5$  im Vertrauensintervall einer zufällig ausgewählten Zahl, die  $\mathcal{N}(5, 2^2)$  folgt?

- Folgender Code: Bestimmt 1000 mal Zufallszahl und zählt wieviele Male  $\mu_0 = 5$  im Vertrauensintervall der Zufallszahl liegt:

```
n <- 1000

r <- rnorm(n = n, mean = 5, sd = 2)
q_u <- qnorm(p = c(0.025), mean = r, sd = 2)
q_o <- qnorm(p = c(0.975), mean = r, sd = 2)

k <- 0

for (i in 1:n) {
  if ((q_u[i] <= 5 & 5 <= q_o[i]) == FALSE) {
    k <- k + 1
  }
}

print(k)
## [1] 47
```

- In 47 von 1000 Fällen liegt  $\mu_0 = 0$  nicht im Vertrauensintervall der Zufallszahlen

- Folgender Code: Macht das 20 mal

```
vi2 <- function(n) {
  r <- rnorm(n = n, mean = 5, sd = 2)
  q_u <- qnorm(p = c(0.025), mean = r, sd = 2)
  q_o <- qnorm(p = c(0.975), mean = r, sd = 2)

  k <- 0

  for (i in 1:n) {
    if ((q_u[i] <= 5 & 5 <= q_o[i]) == FALSE) {
      k <- k + 1
    }
  }
  cat(k, " ")
}

for (i in 1:20) {
  vi2(1000)
}

## 52 52 50 58 46 55 60 53 48 47 56 48 52 50 66 61 47 51 57 42
```

- In etwa 50 von 1000 Fällen liegt  $\mu_0 = 0$  nicht im Vertrauensintervall der Zufallszahlen
- Das sind etwa 5 %


## Graphisch

- Rote Linien zeigen an, wo  $\mu_0 = 5$  nicht im Vertrauensintervall enthalten ist:

```
r <- rnorm(n = 100, mean = 5, sd = 2)
q_u <- qnorm(p = c(0.025), mean = r, sd = 2)
q_o <- qnorm(p = c(0.975), mean = r, sd = 2)

plot(NULL, xlim = c(1, 100), ylim = c(-5, 15), xlab = "", ylab = "")

lines(c(1, 100), c(5, 5), lwd = 3, col = "blue")
for (i in 1:100) {
  lines(c(i, i), c(q_u[i], q_o[i]))
  if ((q_u[i] <= 5 & 5 <= q_o[i]) == FALSE) {
    lines(c(i, i), c(q_u[i], q_o[i]), col = "red", lwd = 3)
  }
}
```



- Hier 100 Vertrauensintervalle
- In 6 Fällen ist  $\mu_0 = 5$  nicht im Vertrauensintervall
- Führen dies oft durch: In etwa 5 % der Fälle liegt  $\mu_0 = 5$  nicht im Vertrauensintervall
- Interpretation: Zu 95 % liegt der wahre Mittelwert im Vertrauensintervall
- Man spricht von einem 95 %-Vertrauensintervall

- Gesehen: Nullhypothese wird verworfen
- Fällt wahres  $\mu$  also aus dem Vertrauensintervall, dann wird Nullhypothese verworfen
- Weiteren Interpretation des Vertrauensintervalls: Enthält alle  $\mu_0$ 's für die Nullhypothese *nicht* verworfen wird
- Es sagt uns also in welchem Intervall sich das wahre  $\mu_0$  befindet
- Gilt nicht absolut: Mit einer bestimmten W'keit liegt wahres  $\mu_0$  in diesem Intervall
- Hier: Wahres  $\mu_0$  liegt zu 95 % im Vertrauensintervall
- Sprechen deswegen auch von einem 95 %-Vertrauensintervall

- Weitere Möglichkeit für Testentscheid:
  - ▶ Liegt  $\mu_0$  der Nullhypothese im Vertrauensintervall, so wird die Nullhypothese *nicht* verworfen
  - ▶ Liegt  $\mu_0$  der Nullhypothese *nicht* im Vertrauensintervall, so wird die Nullhypothese verworfen

- R-Output: Gibt Vertrauensintervall (**confidence interval**) an
- Dieses besagt, dass bei einem Signifikanzniveau von 5 % das wahre  $\mu$  zu 95 % in diesem Intervall liegt
- Mit Vertrauensintervall kann man ebenfalls Testentscheid durchführen

## Beispiel: Waage A

- Nullhypothese
 
$$H_0 : \mu_0 = 80$$
- R-Output: Vertrauensintervall:
 
$$[80.00629, 80.03525]$$
- Zu 95 % liegt das wahre  $\mu$  in diesem Intervall
- Aber  $\mu_0 = 80$  *nicht* in diesem Intervall
- Zu 95 % Sicherheit ist das wahre  $\mu$  *nicht* 80
- Nullhypothese wird verworfen und Alternativhypothese angenommen

## Beispiel: Körpergrösse Frauen

- Nullhypothese:
 
$$H_0 : \mu_0 = 180$$
- R-Output: Vertrauensintervall:
 
$$(-\infty, 169.382]$$
- Zu 95 % liegt das wahre  $\mu$  in diesem Intervall
- $\mu_0 = 180$  *nicht* in diesem Intervall
- Mit 95 % Sicherheit ist das wahre  $\mu$  *nicht* 80
- Nullhypothese verwerfen; Alternativhypothese annehmen

## Bemerkung

- Je schmaler das Vertrauensintervall ist, umso sicherer weiss man, wo sich der wahre Mittelwert befindet

- Ist das Vertrauensintervall schmal, wie

[105.12, 105.23]

so wissen wir sehr genau, wo der wahre Mittelwert mit 95 % Wahrscheinlichkeit liegt

- Ist das Vertrauensintervall breit, wie


[10, 1000]

so besteht grosse Unsicherheit, wo das wahre  $\mu$  liegt

## Nicht-normalverteilte Daten: Wilcoxon-Test

- Alternative zu  $t$ -Test
- Wilcoxon-Test ist der weniger voraussetzt als der  $t$ -Test
- Voraussetzung: Verteilung unter Nullhypothese *symmetrisch* bez.  $\mu_0$
- Annahme:

$X_i \sim F$  iid,  $F$  ist symmetrisch



## Beispiel: Waage A

- R Output:

```
x <- c(79.98, 80.04, 80.02, 80.04, 80.03, 80.03, 80.04, 79.97,
      80.05, 80.03, 80.02, 80, 80.02)

wilcox.test(x, mu = 80, alternative = "two.sided")
##
## Wilcoxon signed rank test with continuity correction
##
## data: x
## V = 69, p-value = 0.0195
## alternative hypothesis: true location is not equal to 80
```

- Auf Signifikanzniveau von 5 % wird Nullhypothese verworfen, da  $p$ -Wert kleiner als 0.05 ist

### Wilcoxon-Test versus $t$ -Test

Der Wilcoxon-Test ist in den allermeisten Fällen dem  $t$ -Test vorzuziehen: Er hat in vielen Situationen oftmals wesentlich grössere Macht (Wahrscheinlichkeit Nullhypothese richtigerweise zu verwerfen)

Selbst in den ungünstigsten Fällen ist er nie viel schlechter

- Vergleich von zwei Messverfahren (Messgerät  $A$  vs. Messgerät  $B$ ): Gibt es einen signifikanten Unterschied?
- Vergleich von zwei Herstellungsverfahren ( $A$  vs.  $B$ ): Welches hat die besseren Eigenschaften (z.B. bzgl. Bruchigkeit von Handy-Displays)?
- Werden männliche Dozenten von weiblichen Studierenden besser als von männlichen Studierenden bewertet?
- Sammeln also jeweils Daten von *zwei* Gruppen

## Gepaarte Stichproben

- Beispiel Messgeräte: Jeder Prüfkörper wird mit *beiden* Messgeräten gemessen
- Pro *Versuchseinheit* (hier: Prüfkörper) zwei Beobachtungen (einmal Gerät  $A$  und einmal Gerät  $B$ )
- Man spricht auch von *gepaarten Stichproben*
- Beide Beobachtungen sind *nicht* unabhängig, da an *gleicher* Versuchseinheit zwei Mal gemessen wird!


## Ungepaarte (unabhängige) Stichproben

- Beispiel Herstellungsverfahren: Stichprobe von Verfahren  $A$  und eine andere Stichprobe von Verfahren  $B$  und messen jedes Objekt aus
- Beobachtungen sind hier *unabhängig*: „Es gibt *nichts*, was sie verbindet“
- Man spricht auch von *ungepaarten (oder unabhängigen) Stichproben*

## Unterscheidung gepaart versus ungepaarte Stichproben


### Gepaarte Stichproben

- Jede Beobachtung einer Gruppe kann eindeutig einer Beobachtung der anderen Gruppe zugeordnet werden
- Stichprobengrösse ist in beiden Gruppen zwangsläufig gleich




### Ungepaarte Stichproben

- Keine Zuordnung von Beobachtungen möglich
- Stichprobengrößen können verschieden sein (müssen aber nicht!)
- Man kann die eine Gruppe vergrössern, ohne dass man die andere vergrössert



## Gepaarte versus ungepaarte Stichproben

- Beispiel: Augeninnendruck; ein Auge behandelt, das andere nicht (gepaarter Test ist angebracht)
- Gemäss Voraussetzungen dürfte auch ein ungepaarter Test angewendet werden



Ungepaart:  
Intuition Teststatistik:  $T = \frac{\bar{X} - \bar{Y}}{\hat{\sigma}_{\bar{X}}}$

Gepaart:  
Differenz  $D_i = X_i - Y_i$   
Teststatistik  $T = \frac{\bar{D}}{\hat{\sigma}_{\bar{D}}}$

## Statistischer t-Test für gepaarte Stichproben mit

- Gepaarte Stichproben: Normalverteilte Daten

$$X_i \sim \mathcal{N}(\mu_X, \sigma_X^2) \quad \text{und} \quad Y_i \sim \mathcal{N}(\mu_Y, \sigma_Y^2)$$

- Betrachten Differenzen

$$D_i = X_i - Y_i$$

- Führen einen t-Test durch

- Normalerweise für die Nullhypothese

$$E(D) = \mu_D = 0$$

- Kein Unterschied!

- Falls Daten nicht normalverteilt → Wilcoxonstest

- R-Output:

```
vorher <- c(25, 25, 27, 44, 30, 67, 53, 53, 52, 60, 28)
nachher <- c(27, 29, 37, 56, 46, 82, 57, 80, 61, 59, 43)

t.test(nachher, vorher, alternative = "two.sided", mu = 0, paired = TRUE,
       conf.level = 0.95)

##
## Paired t-test
##
## data: nachher and vorher
## t = 4.2716, df = 10, p-value = 0.001633
## alternative hypothesis: true difference in means is not equal to 0
## 95 percent confidence interval:
##  4.91431 15.63114
## sample estimates:
## mean of the differences
## 10.27273
```

- Nullhypothese wird auf Signifikanzniveau von 5 % verworfen, da p-Wert 0.001633 kleiner als 0.05



- Unterschied ist also auf dem 5 % Signifikanzniveau signifikant, weil der P-Wert kleiner als 5 % ist
- 95 %-Vertrauensintervall: Mittelwert der Unterschiede  
[4.91431, 15.63114]
- Mit 95 % W'keit ist der Durchschnitt der Differenzen von **nachher** und **vorher** in diesem Bereich

- *Ungepaarte Stichproben*: Daten  $X_i$  und  $Y_j$  normalverteilt, aber ungepaart
- Beispiel: Waage A und B
- Zwei-Stichproben  $t$ -Test für ungepaarte Stichproben mit Nullhypothese

$$\mu_X = \mu_Y$$

- R-Output:

```
x <- c(79.98, 80.04, 80.02, 80.04, 80.03, 80.03, 80.04, 79.97,
      80.05, 80.03, 80.02, 80, 80.02)
y <- c(80.02, 79.94, 79.98, 79.97, 80.03, 79.95, 79.97)

t.test(x, y, alternative = "two.sided", mu = 0, paired = FALSE,
       conf.level = 0.95)

##
## Welch Two Sample t-test
##
## data: x and y
## t = 2.8399, df = 9.3725, p-value = 0.01866
## alternative hypothesis: true difference in means is not equal to 0
## 95 percent confidence interval:
##  0.008490037 0.073048425
## sample estimates:
## mean of x mean of y
## 80.02077 79.98000
```

- Auf Signifikanzniveau 5 % wird Nullhypothese verworfen, da  $p$ -Wert 0.01866 kleiner als 0.05 ist

- Unterschied ist also auf dem 5 % Signifikanzniveau signifikant, weil der P-Wert kleiner als 5 %

- 95 %-Vertrauensintervall: Unterschied in Gruppenmittelwerten:

$$[0.0167, 0.0673]$$

- Mit 95 % W'keit ist der Gruppenmittelwert von **x** um eine Zahl in diesem Bereich grösser als der Gruppenmittelwert von **y**

# Mann-Whitney U-Test (aka Wilcoxon Rank-sum Test)

- Falls Daten nicht normalverteilt
- R-Output:

```
x <- c(79.98, 80.04, 80.02, 80.04, 80.03, 80.03, 80.04, 79.97,  
      80.05, 80.03, 80.02, 80, 80.02)  
  
y <- c(80.02, 79.94, 79.98, 79.97, 80.03, 79.95, 79.97)  
  
wilcox.test(x, y, alternative = "two.sided", mu = 0, paired = FALSE,  
            conf.level = 0.95)  
  
##  
##  Wilcoxon rank sum test with continuity correction  
##  
## data:  x and y  
## W = 76.5, p-value = 0.01454  
## alternative hypothesis: true location shift is not equal to 0
```